LAPORAN PROYEK
MATA KULIAH DATA SAINS
ANALISIS KESENJANGAN KETERSEDIAAN FASILITAS KESEHATAN ANTAR WILAYAH DI SUMATRA PADA TAHUN 2022

Dosen Pengampu:

Nerfita Nikentari, ST., M.Cs., Ph.D

Disusun oleh:

1. Rydhoi Trimaniel Lase	:	2401020061
2. Abdal Ghyfran Kh	:	2401020078
3. M. Afdhal Habibi	:	2401020083
4. Kevin Brian Rizky	:	2401020085
5. M. Rizky Anargya Sofyan	:	2401020089

PROGRAM STUDI TEKNIK INFORMATIKA

JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA

FAKULTAS TEKNIK DAN TEKNOLOGI KEMARITIMAN

UNIVERSITAS MARITIM RAJA ALI HAJI

2026

BAB I

PROBLEM DEFINITION

1.1 Latar Belakang

Fasilitas kesehatan tingkat pertama adalah pintu masuk layanan kesehatan bagi masyarakat. Di Indonesia, Pusat Kesehatan Masyarakat (Puskesmas) menjadi fasilitas yang paling banyak tersebar dan paling dekat dengan penduduk, sehingga jumlah dan sebarannya sering dipakai untuk melihat sejauh mana layanan kesehatan dasar tersedia di suatu daerah. Puskesmas terbagi menjadi dua jenis, yaitu Puskesmas rawat inap yang menyediakan perawatan dengan tempat tidur, dan Puskesmas non rawat inap yang melayani rawat jalan.

Ketersediaan Puskesmas tidak sama di setiap daerah. Pada data Kementerian Kesehatan Semester II 2022 untuk 154 kabupaten/kota di Pulau Sumatra, jumlah Puskesmas per kabupaten/kota berkisar dari 4 unit (Kota Solok dan Kota Padang Panjang) sampai 46 unit (Kabupaten Simalungun), dengan rata-rata 17,56 unit. Namun jumlah unit saja bisa menyesatkan, karena daerah berpenduduk besar tentu membutuhkan fasilitas lebih banyak. Kota Medan, misalnya, memiliki 41 Puskesmas (terbanyak ketiga) tetapi hanya 1,64 Puskesmas per 100.000 penduduk, yang merupakan rasio terendah di Sumatra. Sebaliknya, Kabupaten Kepulauan Anambas hanya memiliki 10 Puskesmas tetapi rasionya 19,88 per 100.000 penduduk, tertinggi di Sumatra dan sekitar 12 kali lipat rasio Kota Medan.

Karena itu, kesenjangan ketersediaan fasilitas kesehatan perlu dilihat dari rasio fasilitas terhadap jumlah penduduk, bukan hanya jumlah unit. Analisis ini memakai data jumlah Puskesmas (Kemenkes) sebagai data utama dan data jumlah penduduk 2022 (BPS) sebagai pembagi rasio. Selain rasio, komposisi Puskesmas rawat inap dan non rawat inap juga berbeda antardaerah: 12 kabupaten/kota tidak memiliki Puskesmas rawat inap, sebagian besar berupa kota.

Untuk menjawab persoalan tersebut, kami memakai pendekatan data science dengan data terbuka pemerintah. Alurnya dimulai dari pengumpulan dan pembersihan data, analisis data eksploratif (EDA), pengukuran kesenjangan antarwilayah, analisis hubungan antarvariabel, sampai pengelompokan wilayah dengan K-Means.

1.2 Rumusan Masalah

1. Bagaimana karakteristik dan sebaran jumlah Puskesmas serta rasio Puskesmas per 100.000 penduduk antarkabupaten/kota di Pulau Sumatra pada tahun 2022?
2. Seberapa besar kesenjangan ketersediaan Puskesmas antarkabupaten/kota dan antarprovinsi?
3. Bagaimana hubungan antara jumlah penduduk, jumlah Puskesmas, dan rasio Puskesmas per 100.000 penduduk, serta bagaimana komposisi Puskesmas rawat inap di tiap wilayah?
4. Bagaimana kabupaten/kota dapat dikelompokkan berdasarkan jumlah penduduk, rasio Puskesmas, dan proporsi Puskesmas rawat inap?

1.3 Tujuan Analisis

1. Mendeskripsikan karakteristik dan sebaran jumlah Puskesmas dan rasio per 100.000 penduduk antarkabupaten/kota.
2. Mengukur tingkat kesenjangan ketersediaan Puskesmas antarwilayah dengan ukuran rasio maks/min, koefisien variasi, dan indeks Gini.
3. Mengidentifikasi wilayah dengan ketersediaan tertinggi dan terendah, hubungan dengan jumlah penduduk, serta komposisi jenis Puskesmasnya.
4. Mengelompokkan kabupaten/kota dengan K-Means dan menjelaskan karakteristik tiap kelompok.

1.4 Pertanyaan Data Science

Bagaimana ketersediaan fasilitas kesehatan tersebar antarwilayah di Sumatra, dan wilayah mana yang tertinggal dibanding yang lain? Pertanyaan ini dikembangkan menjadi: Seberapa timpang rasio Puskesmas terhadap penduduk antarwilayah, apakah jumlah penduduk berkaitan dengan rasio tersebut, dan bisakah kabupaten/kota dikelompokkan menurut tingkat ketersediaannya? Hubungan antara pertanyaan, jenis analisis, dan metode yang kami pakai ada di Tabel 1.1.

Tabel 1.1 Pertanyaan, jenis analisis, dan metode

Bagian pertanyaan	Jenis analisis	Metode
Karakteristik antarwilayah	Eksploratif dan deskriptif	Statistik deskriptif, EDA
Besar kesenjangan	Pengukuran ketimpangan	Rasio maks/min, koefisien variasi, indeks Gini
Faktor yang berhubungan	Analisis hubungan	Korelasi Pearson
Komposisi jenis fasilitas	Eksploratif	Persentase Puskesmas rawat inap per wilayah
Pengelompokan daerah	Unsupervised learning	K-Means (Elbow dan Silhouette)

1.5 Ruang Lingkup dan Batasan

- Cakupan analisis adalah 154 kabupaten/kota di 10 provinsi Pulau Sumatra (Aceh, Sumatera Utara, Sumatera Barat, Riau, Kepulauan Riau, Jambi, Sumatera Selatan, Bengkulu, Lampung, dan Kepulauan Bangka Belitung).
- Data hanya untuk tahun 2022: Puskesmas pada kondisi akhir Desember 2022 dan jumlah penduduk 2022 berupa proyeksi BPS. Tren antartahun tidak bisa dianalisis, perbandingan dilakukan antardaerah.
- Data fasilitas hanya memuat Puskesmas (rawat inap, non rawat inap, dan jumlahnya). Rumah sakit, klinik, dan tenaga kesehatan belum termasuk.
- Variabel pendukung yang dipakai hanya jumlah penduduk. Laju pertumbuhan, kepadatan, dan rasio jenis kelamin tidak dipakai karena tidak tersedia lengkap untuk 154 daerah. Luas wilayah juga tidak dipakai karena tidak ada di data.
- Jumlah data 154 baris, sehingga hasil dibaca sebagai pola awal. Tidak ada analisis sebab-akibat, dan model prediksi tidak dipakai karena fokusnya adalah kesenjangan.

BAB II

DATA UNDERSTANDING

2.1 Sumber Data

Analisis ini memakai dua dataset. Data utama berasal dari Kementerian Kesehatan Republik Indonesia, yaitu Data Puskesmas Teregistrasi Semester II Tahun 2022 (Lampiran I: Jumlah Puskesmas menurut Kabupaten/Kota) pada Keputusan Menteri Kesehatan Nomor HK.01.07/MENKES/1351/2023 yang ditetapkan 16 Mei 2023. Dokumen aslinya berformat PDF, lalu tabelnya diketik ulang ke spreadsheet. Data pendukung berupa jumlah penduduk 2022 per kabupaten/kota, dikumpulkan dari publikasi BPS di tiap provinsi. Rincian kedua dataset ada di Tabel 2.1.

Tabel 2.1 Metadata dataset yang digunakan

Dataset	Sumber	Tahun	Baris	Variabel	Format	Peran
Jumlah Puskesmas menurut kabupaten/kota	Kemenkes RI (KMK HK.01.07/ MENKES/1351/2023)	Semester II 2022	154	6	CSV	Data utama
Jumlah penduduk menurut kabupaten/kota	BPS (publikasi provinsi, lihat Tabel 2.2)	2022	154 + 1 baris total Sumatra	12	XLSX	Data pendukung

Sumber data penduduk tidak sama di semua provinsi. Rinciannya ada di Tabel 2.2.

Tabel 2.2 Sumber data penduduk 2022 per provinsi

Provinsi	Sumber
Aceh	BPS Provinsi Aceh, tabel penduduk menurut kab/kota 2022 (proyeksi SP2020)
Sumatera Utara	BPS Provinsi Sumatera Utara, jumlah penduduk menurut jenis kelamin kab/kota 2022
Sumatera Barat	BPS Provinsi Sumatera Barat, dalam Profil

Provinsi	Sumber
	Kesehatan Provinsi Sumatera Barat 2022
Riau	BPS Provinsi Riau dan BPS Kota Pekanbaru, jumlah penduduk menurut kab/kota 2022
Kepulauan Riau	BPS Long Form Sensus Penduduk 2020 (hasil tahun 2022)
Jambi	BPS Provinsi Jambi, dalam Profil Kesehatan Provinsi Jambi 2022 (Tabel 1.1)
Sumatera Selatan	BPS Provinsi Sumatera Selatan, dalam Profil Kesehatan Provinsi Sumatera Selatan 2022 (Tabel 1.1)
Bengkulu	BPS Long Form Sensus Penduduk 2020 (hasil tahun 2022)
Lampung	BPS Provinsi Lampung dan Profil Kesehatan Provinsi Lampung 2022 (Tabel 2.2)
Kepulauan Bangka Belitung	BPS Provinsi Kepulauan Bangka Belitung, Indikator Sosial 2023 (data tahun 2022)

Jumlah penduduk adalah angka proyeksi atau estimasi BPS untuk 2022, bukan hasil pencacahan. Karena tiap provinsi memakai publikasi yang berbeda, basis proyeksinya bisa sedikit berbeda. Sebagai pembanding, jumlah penduduk gabungan 154 kabupaten/kota (59.915.973 jiwa) hanya berbeda 0,10% dari total Long Form SP2020 untuk tahun 2022 (59.974.662 jiwa), dengan selisih terbesar di Riau (0,89%).

2.2 Deskripsi Dataset

Data mencakup 154 kabupaten/kota di 10 provinsi Pulau Sumatra, terdiri dari 120 kabupaten dan 34 kota. Satu baris mewakili satu kabupaten/kota pada tahun 2022. Secara keseluruhan terdapat 2.704 Puskesmas, yaitu 1.618 non rawat inap (59,8%) dan 1.086 rawat inap (40,2%), melayani 59.915.973 penduduk. Rasio Puskesmas untuk seluruh Sumatra adalah 4,51 per 100.000 penduduk. Rinciannya per provinsi ada di Tabel 2.3.

Tabel 2.3 Puskesmas dan penduduk per provinsi, 2022 (urut rasio tertinggi)

Provinsi	Kab/Kota	Penduduk (jiwa)	Non rawat inap	Rawat inap	Total Puskesmas	Per 100.000 penduduk	Rawat inap (%)
Bengkulu	10	2.060.092	127	52	179	8,69	29,1
Aceh	23	5.407.800	183	179	362	6,69	49,4
Jambi	11	3.631.136	111	96	207	5,70	46,4
Sumatera Barat	19	5.640.629	165	115	280	4,96	41,1
Kepulauan Bangka Belitung	7	1.491.986	37	27	64	4,29	42,2
Kepulauan Riau	7	2.179.820	61	32	93	4,27	34,4
Sumatera Utara	33	15.115.206	421	194	615	4,07	31,5
Sumatera Selatan	17	8.657.008	230	118	348	4,02	33,9
Riau	12	6.555.750	122	116	238	3,63	48,7
Lampung	15	9.176.546	161	157	318	3,47	49,4
Total Sumatra	**154**	**59.915.973**	**1.618**	**1.086**	**2.704**	**4,51**	**40,2**

Karena datanya hanya satu tahun, kami tidak bisa melihat perubahan dari tahun ke tahun, jadi analisis bersifat perbandingan antardaerah. Selain itu, kedua dataset memakai penulisan nama daerah yang berbeda (misalnya Labuhan Batu dan Labuhanbatu), sehingga penggabungannya perlu penyeragaman nama (dibahas di Bab III).

2.3 Variabel

Tabel 2.4 Daftar variabel

Nama kolom	Arti	Satuan	Tipe data	Peran
provinsi	Nama provinsi	-	Teks	Identitas
kode	Kode kabupaten/kota (4	-	Teks	Identitas

Nama kolom	Arti	Satuan	Tipe data	Peran
	digit)			
kab_kota	Nama kabupaten atau kota	-	Teks	Identitas, kunci gabung
non_ri	Jumlah Puskesmas non rawat inap	Unit	Bilangan bulat	Indikator
ri	Jumlah Puskesmas rawat inap	Unit	Bilangan bulat	Indikator
total	Jumlah seluruh Puskesmas (non_ri + ri)	Unit	Bilangan bulat	Indikator utama
penduduk	Jumlah penduduk 2022 (ribu jiwa × 1.000)	Jiwa	Bilangan bulat	Pembagi rasio

Penduduk semula tercatat dalam ribu jiwa, lalu dikonversi ke jiwa. Ketelitiannya berbeda antarprovinsi: 100 jiwa untuk Aceh, 10 jiwa untuk Riau, dan 1 jiwa untuk provinsi lain, sehingga rasio daerah kecil di Aceh sedikit kurang presisi.

File data pendukung juga memuat laju pertumbuhan, persentase terhadap total provinsi, kepadatan, dan rasio jenis kelamin. Empat kolom ini tidak dipakai: laju pertumbuhan hanya tersedia untuk 42 daerah, kepadatan untuk 104 daerah, dan rasio jenis kelamin untuk 80 daerah, karena tidak semua provinsi menerbitkannya pada tabel 2022. Persentase terhadap total provinsi lengkap, tetapi hanya mengulang informasi jumlah penduduk.

2.4 Statistik Deskriptif

Statistik deskriptif dihitung dengan Python (pandas). Hasilnya ada di Tabel 2.5. Variabel rasio per 100.000 penduduk dan persen_ri adalah variabel turunan yang dibuat pada Bab III (bagian 3.5), ditampilkan di sini agar sebarannya bisa dibaca bersama. Semua variabel terisi lengkap untuk 154 daerah.

Tabel 2.5 Statistik deskriptif (n = 154 kabupaten/kota)

Variabel	Rata-rata	Std	Min	Q1	Median	Q3	Maks	Modus	Rentang
penduduk (jiwa)	389.064,76	355.888,42	43.200	178.275,75	300.754,5	442.152,75	2.494.512	267.275	2.451.312
non_ri (unit)	10,51	6,91	0	6,00	8,5	14,00	42	7	42
ri (unit)	7,05	4,95	0	4,00	7,0	10,00	27	7	27
total (unit)	17,56	8,33	4	11,25	16,0	22,00	46	15	42
rasio per 100.000	6,09	3,28	1,64	4,16	5,21	7,29	19,88	-	18,24
persen_ri (%)	40,33	23,11	0,00	25,00	39,01	54,89	100,00	0	100,00

Ringkasan tiap variabel

- Jumlah penduduk. Rata-rata 389.065 jiwa dan median 300.755 jiwa. Terendah Kota Sabang (43.200) dan tertinggi Kota Medan (2.494.512), selisihnya 57,7 kali lipat. Kemiringannya sangat tinggi (2,83), artinya kebanyakan daerah berpenduduk kecil sampai sedang dan segelintir daerah sangat besar.
- Jumlah Puskesmas (total). Rata-rata 17,56 unit dan median 16 unit. Terendah 4 unit (Kota Solok dan Kota Padang Panjang) dan tertinggi 46 unit (Kabupaten Simalungun), selisihnya 11,5 kali lipat. Kemiringannya lebih rendah (0,85).
- Puskesmas non rawat inap dan rawat inap. Rata-rata 10,51 dan 7,05 unit. Dua daerah tidak punya Puskesmas non rawat inap (Kabupaten Solok Selatan dan Lampung Barat). Dua belas daerah tidak punya Puskesmas rawat inap: Kota Banda Aceh, Kota Lhokseumawe, Kota Pematang Siantar, Kota Tebing Tinggi, Kota Padang, Kota Padang Panjang, Kota Bukittinggi, Kota Payakumbuh, Kota Pariaman, Kabupaten Penukal Abab Lematang Ilir, Kota Palembang, dan Kota Batam.

- Rasio per 100.000 penduduk. Rata-rata 6,09 dan median 5,21, dengan rentang 1,64 (Kota Medan) sampai 19,88 (Kabupaten Kepulauan Anambas). Lima tertinggi: Kepulauan Anambas (19,88), Kepulauan Mentawai (16,78), Bengkulu Tengah (16,69), Natuna (16,38), dan Simeulue (15,81). Lima terendah: Kota Medan (1,64), Kota Batam (1,65), Deli Serdang (1,69), Kota Pekanbaru (2,09), dan Kota Palembang (2,46).
- Persentase Puskesmas rawat inap (persen_ri). Rata-rata 40,33%. Di 12 daerah nilainya 0%, dan di dua daerah 100% (Solok Selatan dan Lampung Barat). Rata-rata kabupaten (45,9%) jauh di atas kota (20,8%). Rasio Puskesmas kabupaten juga lebih tinggi (rata-rata 6,40) dibanding kota (4,99).

Ukuran Kesenjangan

Kesenjangan diukur dengan koefisien variasi (CV, simpangan baku dibagi rata-rata), indeks Gini (0 berarti merata sempurna, 1 berarti sangat timpang), dan rasio nilai maksimum terhadap minimum. Hasilnya ada di Tabel 2.6.

Tabel 2.6 Ukuran kesenjangan antarkabupaten/kota (n = 154)

Variabel	CV	Indeks Gini	Maks/Min
penduduk	0,92	0,41	57,7
total Puskesmas	0,47	0,26	11,5
rasio per 100.000 penduduk	0,54	0,27	12,1

Puskesmas tersebar jauh lebih merata (Gini 0,26) dibanding penduduk (Gini 0,41). Akibatnya, daerah berpenduduk besar mendapat rasio rendah dan daerah berpenduduk kecil mendapat rasio tinggi. Kesenjangan rasio antarkabupaten/kota mencapai 12,1 kali lipat. Antarprovinsi, selisihnya lebih kecil: rasio Bengkulu (8,69) sekitar 2,5 kali rasio Lampung (3,47), karena rata-rata provinsi meredam perbedaan di dalamnya.

Hubungan Awal Antarvariabel

Korelasi Pearson dihitung untuk melihat apakah jumlah penduduk berkaitan dengan jumlah Puskesmas dan rasio. Penduduk memakai logaritma natural (ln_penduduk) karena sebarannya sangat miring. Hasilnya ada di Tabel 2.7.

Tabel 2.7 Korelasi Pearson (n = 154)

Pasangan variabel	r
ln_penduduk dan total Puskesmas	0,80
penduduk (jiwa) dan total Puskesmas	0,76
ln_penduduk dan rasio per 100.000	−0,71
penduduk (jiwa) dan rasio per 100.000	−0,53
total Puskesmas dan rasio per 100.000	−0,23
persen_ri dan rasio per 100.000	0,12

Daerah yang lebih padat penduduknya memang punya Puskesmas lebih banyak (r = 0,80), tetapi pertambahannya tidak mengikuti pertambahan penduduk, sehingga rasionya turun (r = −0,71). Proporsi Puskesmas rawat inap hampir tidak berhubungan dengan rasio (r = 0,12). Ini hanya hubungan statistik dan tidak berarti sebab-akibat.

Outlier

Outlier dicari dengan metode IQR: sebuah nilai dianggap outlier kalau berada di bawah Q1 − 1,5 × IQR atau di atas Q3 + 1,5 × IQR (IQR = Q3 − Q1). Hasilnya ada di Tabel 2.8.

Tabel 2.8 Outlier menurut metode IQR

Variabel	Batas bawah – atas	Jumlah	Daerah outlier
non_ri	−6,00 – 26,00	5	Kota Palembang (42), Simalungun (36), Nias Selatan (29), Lampung Tengah (29), Kota Medan (28)
ri	−5,00 – 19,00	3	Deli Serdang (27), Indragiri Hilir (25), Aceh Besar (24)
total	−4,88 – 38,12	4	Simalungun (46), Kota Palembang (42), Kota Medan (41), Lampung Tengah (39)
penduduk	−217.539,75 –	14	Kota Medan

Variabel	Batas bawah – atas	Jumlah	Daerah outlier
	837.968,25		(2.494.512), Deli Serdang (1.953.986), Kota Palembang (1.707.996), Lampung Tengah (1.500.022), Kota Batam (1.269.413), dan 9 daerah lain
rasio per 100.000	−0,54 – 11,98	12	Kep. Anambas (19,88), Kepulauan Mentawai (16,78), Bengkulu Tengah (16,69), Natuna (16,38), Simeulue (15,81), Pakpak Bharat (14,65), Nias Barat (14,23), Kota Sabang (13,89), Lingga (12,64), Aceh Jaya (12,50), Kaur (12,34), Lebong (12,12)
persen_ri	−19,83 – 99,72	2	Solok Selatan (100), Lampung Barat (100)

Semua outlier ada di sisi atas, karena batas bawahnya bernilai negatif atau tidak terlampaui. Pola yang terlihat: outlier jumlah Puskesmas dan penduduk umumnya kota besar atau kabupaten berpenduduk besar (Medan, Palembang, Deli Serdang, Lampung Tengah), sedangkan outlier rasio umumnya daerah kepulauan atau berpenduduk kecil (Anambas, Mentawai, Natuna, Simeulue, Sabang). Setelah penduduk diubah ke logaritma natural, outliernya turun dari 14 menjadi 3 (Kota Medan, Deli Serdang, dan Kota Sabang). Semua outlier masih berupa angka yang masuk akal, jadi tidak dianggap kesalahan data.

Jawaban atas Pertanyaan Awal

- Wilayah dengan rasio Puskesmas tertinggi: Kabupaten Kepulauan Anambas (19,88 per 100.000), terendah: Kota Medan (1,64). Berdasarkan jumlah unit, terbanyak Kabupaten Simalungun (46), tersedikit Kota Solok dan Kota Padang Panjang (4).
- Distribusi jumlah penduduk dan rasio miring ke kanan: kebanyakan daerah berada di rentang rendah sampai sedang, dengan sedikit daerah yang sangat tinggi.
- Kesenjangan rasio antarkabupaten/kota mencapai 12,1 kali lipat (Gini 0,27), sedangkan antarprovinsi 2,5 kali lipat (Bengkulu tertinggi, Lampung terendah).
- Jumlah penduduk berkaitan kuat dengan jumlah Puskesmas ($r = 0,80$) dan berkaitan negatif dengan rasio ($r = -0,71$).
- Data kosong dan data ganda: tidak ada. Outlier: ada pada semua variabel utama, seluruhnya di sisi atas.

BAB III

DATA PREPARATION

3.1 Data Cleaning

1. Membaca CSV Puskesmas (154 baris, 6 kolom) dan sheet Penduduk_BPS (155 baris: 154 kabupaten/kota dan 1 baris total Sumatra).
2. Memisahkan baris total Sumatra dari data penduduk. Baris ini tidak dianalisis dan hanya dipakai untuk verifikasi.
3. Menyimpan kode kabupaten/kota sebagai teks 4 digit dan membuang spasi berlebih.
4. Memastikan kolom angka bertipe bilangan bulat dan tidak negatif. Penduduk memakai kolom jiwa (ribu jiwa × 1.000).
5. Menyeragamkan nama daerah supaya kedua dataset bisa digabung (bagian 3.4).
6. Memeriksa data kosong, data ganda, penduduk nol atau negatif, konsistensi non_ri + ri = total, jumlah baris per provinsi (harus 23, 33, 19, 12, 11, 17, 10, 15, 7, dan 7), serta kecocokan total dengan sumber.

Tabel 3.1 Hasil pemeriksaan data

Pemeriksaan	Data Puskesmas	Data penduduk
Jumlah baris dianalisis	154	154 (155 sebelum baris total dikeluarkan)
Kode kab/kota ganda	0	0
Data kosong pada kolom wajib	0	0
Nilai negatif atau nol	0	0
Konsistensi internal	non_ri + ri = total pada 154 dari 154 baris	Jumlah 154 daerah = baris total Sumatra (59.915.973 jiwa)
Total vs sumber resmi	Selisih 0 pada 10 provinsi (total 2.704 unit)	-
Kode kab/kota di kedua file	154 dari 154 kode identik	

Seluruh pemeriksaan lolos tanpa ada baris yang dihapus atau nilai yang diubah.

3.2 Missing Value

Tidak ada data kosong pada variabel yang dipakai (Tabel 3.2). Jadi tidak ada nilai yang perlu diisi atau dihapus. Nilai 0 pada Puskesmas rawat inap (12 daerah) dan non rawat inap (2 daerah) bukan data kosong, melainkan memang tidak ada Puskesmas jenis tersebut, dan total tiap daerah tetap cocok dengan dokumen resmi, sehingga nilai 0 dipertahankan.

Tabel 3.2 Data kosong per variabel

Variabel	Jumlah data	Data kosong	Nilai 0
non_ri	154	0	2
ri	154	0	12
total	154	0	0
penduduk	154	0	0

Kolom laju pertumbuhan, kepadatan, dan rasio jenis kelamin pada data penduduk memang banyak yang kosong (berturut-turut 112, 50, dan 74 dari 154 daerah) karena tidak semua provinsi menerbitkannya. Kolom ini tidak dipakai dan sel kosongnya tidak diisi atau diimputasi.

3.3 Outlier

Outlier dideteksi dengan metode IQR dan hasilnya sudah ditunjukkan pada Tabel 2.8. Audit outlier untuk tiga variabel Puskesmas dilakukan dengan skrip Python (Google Colab) pada salinan data, sehingga data asli tidak diubah. Skrip menghitung Q1, Q3, IQR, batas bawah, dan batas atas (Tabel 3.3), lalu menggabungkan semua daerah yang menjadi kandidat outlier supaya tidak dihitung dua kali. Tiap kandidat diberi kolom variabel pemicu dan status verifikasi sumber, yaitu kodenya dicocokkan dengan dokumen resmi KMK.

Tabel 3.3 Ringkasan IQR variabel Puskesmas

Variabel	Q1	Q3	IQR	Batas bawah	Batas atas	Jumlah kandidat
Puskesmas Non Rawat Inap	6,00	14,00	8,00	−6,00	26,00	5
Puskesmas Rawat Inap	4,00	10,00	6,00	−5,00	19,00	3

Variabel	Q1	Q3	IQR	Batas bawah	Batas atas	Jumlah kandidat
Jumlah Puskesmas	11,25	22,00	10,75	−4,88	38,12	4

Hasilnya, 8 kabupaten/kota unik menjadi kandidat outlier (Tabel 3.4). Seluruhnya berstatus sesuai dengan sumber resmi KMK, sehingga tidak ada yang perlu diperiksa lanjut. Hasil audit diekspor ke file hasil_audit_data_cleaning_puskesmas.xlsx yang berisi sheet Data_Asli, Audit_Outlier, dan Ringkasan_IQR.

Tabel 3.4 Kandidat outlier dan status verifikasi sumber

Provinsi	Kode	Kabupaten /Kota	Non rawat inap	Rawat inap	Jumlah	Variabel pemicu	Status verifikasi
Aceh	1106	Aceh Besar	4	24	28	Rawat inap	Sesuai KMK
Sumatera Utara	1207	Deli Serdang	6	27	33	Rawat inap	Sesuai KMK
Sumatera Utara	1208	Simalungun	36	10	46	Non rawat inap, Jumlah	Sesuai KMK
Sumatera Utara	1214	Nias Selatan	29	7	36	Non rawat inap	Sesuai KMK
Sumatera Utara	1271	Kota Medan	28	13	41	Non rawat inap, Jumlah	Sesuai KMK
Riau	1404	Indragiri Hilir	5	25	30	Rawat inap	Sesuai KMK
Sumatera Selatan	1671	Kota Palembang	42	0	42	Non rawat inap, Jumlah	Sesuai KMK
Lampung	1802	Lampung Tengah	29	10	39	Non rawat inap, Jumlah	Sesuai KMK

Keputusan kami: outlier dibiarkan dan tidak dibuang. Alasannya ada tiga. Pertama, nilainya masuk akal dan Puskesmasnya cocok dengan total resmi KMK, sedangkan penduduknya berasal dari publikasi resmi BPS, jadi bukan salah input. Kedua, datanya hanya 154 baris dan setiap daerah adalah satu unit analisis yang harus tetap ada. Ketiga, daerah ekstrem justru penting untuk pertanyaan tentang kesenjangan, misalnya Kepulauan Anambas yang rasionya tertinggi dan Kota Medan yang terendah.

Outlier bisa memengaruhi rata-rata, koefisien variasi, korelasi, dan hasil K-Means. Karena itu, jumlah penduduk diubah ke logaritma natural dan semua fitur K-Means distandarkan (bagian 3.5). Pengaruh outlier dibahas lagi saat mengevaluasi hasil.

3.4 Data Integration

Data Puskesmas dan data penduduk digabung berdasarkan nama daerah. Kuncinya adalah gabungan provinsi, nama daerah tanpa awalan Kota atau Kab., dan penanda kota atau kabupaten. Penanda terakhir diperlukan agar daerah kembar nama tidak tertukar, yaitu Kabupaten Solok (397.829 jiwa) dan Kota Solok (75.850 jiwa). Nama ditulis huruf kecil dan dirapikan sebelum dicocokkan.

Dari 154 daerah, 141 cocok langsung setelah huruf dan awalan disamakan, dan 13 daerah perlu penyeragaman ejaan secara manual (Tabel 3.5).

Tabel 3.5 Penyeragaman nama daerah

Nama di data Puskesmas	Nama di data penduduk
LABUHAN BATU	Labuhanbatu
LABUHAN BATU SELATAN	Labuhanbatu Selatan
LABUHAN BATU UTARA	Labuhanbatu Utara
TOBA SAMOSIR	Toba
KOTA PEMATANG SIANTAR	Kota Pematangsiantar
KOTA TANJUNG BALAI	Kota Tanjungbalai
KOTA PADANG SIDEMPUAN	Kota Padangsidimpuan
KOTA SAWAH LUNTO	Kota Sawahlunto
KOTA BUKIT TINGGI	Kota Bukittinggi
MUKO-MUKO	Mukomuko
KEP. ANAMBAS	Kepulauan Anambas

Nama di data Puskesmas	Nama di data penduduk
KOTA BATAM	Batam
KOTA TANJUNG PINANG	Tanjung Pinang

Hasil penggabungan diperiksa ulang. Seluruh 154 daerah terpasang tanpa satu pun yang tidak cocok, tanpa baris ganda, dengan jumlah per provinsi sesuai (23, 33, 19, 12, 11, 17, 10, 15, 7, dan 7). Total Puskesmas tetap 2.704 unit dan total penduduk tetap 59.915.973 jiwa. Sebagai pemeriksaan silang, kode kabupaten/kota di kedua file ternyata identik untuk 154 dari 154 daerah, sehingga penggabungan lewat nama menghasilkan pasangan yang sama dengan penggabungan lewat kode.

3.5 Feature Engineering

Fitur yang dibuat dari data gabungan:

- rasio per 100.000 penduduk = total ÷ penduduk × 100.000, sebagai ukuran utama ketersediaan fasilitas.
- persen_ri = ri ÷ total × 100, yaitu persentase Puskesmas rawat inap di tiap daerah, untuk melihat komposisi jenis fasilitas.
- ln_penduduk = logaritma natural dari penduduk. Jumlah penduduk sangat miring ke kanan (kemiringan 2,83), dan setelah diubah menjadi 0,11, sehingga lebih layak untuk K-Means.
- jenis_wilayah (kabupaten atau kota), diturunkan dari awalan nama daerah (120 kabupaten dan 34 kota).

Untuk K-Means, tiga fitur dipakai: ln_penduduk, rasio per 100.000 penduduk, dan persen_ri. Karena skalanya sangat berbeda, ketiganya distandarkan dengan Z-score, yaitu nilai dikurangi rata-rata lalu dibagi simpangan baku. Hasilnya ada di Tabel 3.6.

Tabel 3.6 Statistik fitur setelah standardisasi (n = 154)

Fitur terstandarisasi	Rata-rata	Std	Min	Maks
Z_ln_penduduk	0,00	1,00	−2,51	2,84
Z_rasio	0,00	1,00	−1,36	4,22
Z_persen_ri	0,00	1,00	−1,75	2,59

Rata-rata semua fitur 0 dan simpangan bakunya 1 (pandas menampilkan 1,0033 karena menghitung simpangan baku sampel, sedangkan standardisasi memakai simpangan baku populasi). Nilai Z_rasio maksimum 4,22 adalah Kabupaten Kepulauan Anambas, yang masih jauh dari daerah lain sehingga perlu diperhatikan saat membaca hasil K-Means.

3.6 Data yang Disiapkan untuk Analisis

Keluaran tahap ini adalah satu tabel bersih berisi 154 baris dengan kolom provinsi, kode, kab_kota, jenis_wilayah, non_ri, ri, total, penduduk, rasio per 100.000 penduduk, persen_ri, ln_penduduk, serta tiga kolom Z-score (Z_ln_penduduk, Z_rasio, dan Z_persen_ri). Hasilnya disimpan di file hasil_tahap4_normalisasi_puskesmas_2022.xlsx. Kolom aslinya tidak berubah karena pembersihan tidak menghapus baris atau mengganti nilai apa pun. Pemeriksaan tetap dicatat agar jelas bahwa validasi sudah dilakukan.