PROJECT DATA SAINS

Sumber Data : Satu Data

Alur Data Science lengkap: problem → data → preprocessing → eksplorasi → analisis/model → evaluasi → insight/rekomendasi.

Contoh Pilihan Studi Kasus Data Science dari data.go.id

Secara Umum

Kelompok	Studi Kasus	Teknik Utama
1	Kemiskinan & kesehatan	Regression
2	Pelayanan kesehatan peserta didik	Clustering
3	Kepadatan penduduk	Regression/Clustering
4	Stunting	Classification
5	Kualitas lingkungan	PCA + Clustering
6	APBD & pelayanan publik	Regression
7	Kesenjangan pembangunan wilayah kepulauan	PCA + Clustering

Secara Khusus

No	Studi Kasus	Dataset yang digunakan	Analisis Data Science
1	**Pemetaan dan Prediksi Kemiskinan Daerah**	Data kemiskinan, garis kemiskinan, P3KE	EDA, korelasi, clustering, regresi
2	**Analisis UMKM Berdasarkan Skala dan Sektor Ekonomi**	Dataset UMKM	EDA, clustering, segmentasi
3	**Analisis Hubungan UMKM dengan Tenaga Kerja**	Jumlah UMKM + jumlah tenaga kerja	Korelasi, regresi
4	**Analisis Ketimpangan Akses Kesehatan**	Jumlah sarana kesehatan per wilayah	EDA, rasio fasilitas/penduduk, clustering
5	**Prediksi Tingkat Kemiskinan Berdasarkan Indikator Sosial**	Kemiskinan + pendidikan + kesehatan + ekonomi	Regresi / machine learning
6	**Analisis Pendidikan Penduduk dan Kondisi Sosial Ekonomi**	Data pendidikan + kemiskinan	Korelasi, regresi, clustering
7	**Analisis Infrastruktur dan Pembangunan Daerah**	Infrastruktur + data wilayah	EDA, clustering
8	**Analisis Harga Bahan Pokok**	Dataset Tingkat Harga Daerah	Time series, forecasting
9	**Analisis Penerima Bantuan Sosial**	Data penerima bantuan/PKH	EDA, clustering, klasifikasi
10	**Analisis Lingkungan dan Pembangunan Berkelanjutan**	Dataset lingkungan	EDA, korelasi, clustering

Data.go.id sendiri menyediakan berbagai topik seperti **Ekonomi dan Industri, Lingkungan dan Sumber Daya Alam, Perlindungan Sosial dan Kesehatan, Pembangunan Daerah, serta Pendidikan dan Tenaga Kerja**. (Data.go.id)

Pertanyaan studi kasus

Mahasiswa diminta menjawab:

"Bagaimana karakteristik kemiskinan antarwilayah dan faktor apa yang memiliki hubungan dengan tingkat kemiskinan?"

Kemudian dapat dikembangkan menjadi:

"Bisakah tingkat kemiskinan suatu wilayah diprediksi berdasarkan indikator sosial-ekonomi yang tersedia?"

C. Tugas yang diberikan kepada mahasiswa

Project 1

1. Data Collection

Mahasiswa mencari dan mengunduh dataset dari:

https://data.go.id/

Minimal menggunakan **2 dataset** yang relevan.

Contoh:

- Dataset kemiskinan
- Dataset garis kemiskinan
- Dataset pendidikan
- Dataset kesehatan
- Dataset ekonomi

Mahasiswa harus mencatat:

- Nama dataset
- Instansi sumber
- Tahun data
- Jumlah baris
- Jumlah variabel
- Format data
- URL dataset

2. Data Understanding

Mahasiswa melakukan:

- Identifikasi variabel
- Tipe data
- Jumlah observasi
- Missing value
- Duplikasi
- Outlier
- Distribusi data

Contoh pertanyaan:

a. Wilayah mana yang memiliki tingkat kemiskinan tertinggi?

b. Bagaimana distribusi kemiskinan antarwilayah?

c. Apakah terdapat data yang kosong?

d. Apakah terdapat outlier?

3. Data Preprocessing

Mahasiswa melakukan:

- Cleaning data
- Mengatasi missing value
- Menghapus duplikasi
- Konversi tipe data
- Normalisasi/standardisasi jika diperlukan
- Menggabungkan beberapa dataset

D. Exploratory Data Analysis

Mahasiswa membuat minimal **5 visualisasi**.

Contoh:

Visualisasi 1

Top 10 wilayah dengan tingkat kemiskinan tertinggi

Bar chart.

Visualisasi 2

Perubahan kemiskinan dari tahun ke tahun

Line chart.

Visualisasi 3

Hubungan pendidikan dengan kemiskinan

Scatter plot.

Visualisasi 4

Distribusi tingkat kemiskinan

Histogram/boxplot.

Visualisasi 5

Perbandingan kemiskinan antarwilayah

Heatmap/bar chart.

E. Analisis Statistik

Mahasiswa menghitung:

Korelasi

Misalnya:

$r = Cor(X,Y)$

untuk melihat hubungan antara:

- pendidikan ↔ kemiskinan
- jumlah fasilitas kesehatan ↔ kemiskinan
- garis kemiskinan ↔ kemiskinan
- jumlah penduduk ↔ kemiskinan

Mahasiswa kemudian menjelaskan:

Apakah hubungan tersebut positif, negatif, atau lemah?

Catatan: korelasi tidak otomatis berarti hubungan sebab-akibat.

Project 2

F. Machine Learning

Agar tugas benar-benar mencerminkan **Data Science**, mahasiswa diwajibkan menggunakan minimal **2 algoritma machine learning**.

Contoh:

Model 1

- Logistic Regression

Model 2

- Random Forest

Opsional:

- Decision Tree
- KNN
- SVM
- XGBoost
- Gradient Boosting

Pilihan 1 — Clustering

Tujuan:

Mengelompokkan wilayah berdasarkan karakteristik kemiskinan dan indikator sosial-ekonomi.

Contoh:

Cluster 1 → karakteristik kemiskinan rendah
Cluster 2 → karakteristik kemiskinan sedang
Cluster 3 → karakteristik kemiskinan tinggi

Mahasiswa harus menentukan jumlah cluster menggunakan misalnya:

- Elbow Method
- Silhouette Score

Pilihan 2 — Regression

Target:

Tingkat kemiskinan

Feature:

- pendidikan
- kesehatan
- garis kemiskinan
- jumlah penduduk
- indikator ekonomi

Model dapat menggunakan:

- Linear Regression
- Random Forest Regression
- Decision Tree Regression

Evaluasi:

- MAE
- RMSE
- R^2

Contoh Studi Kasus

Analisis UMKM dan Tenaga Kerja

Menurut dataset UMKM yang tersedia di data.go.id, terdapat data berdasarkan skala usaha (mikro, kecil, menengah), sektor ekonomi, jumlah tenaga kerja, dan nilai omzet. Dataset tersebut berasal antara lain dari Pemerintah Kota Makassar. (Data.go.id)

Pertanyaan penelitian

"Bagaimana karakteristik UMKM berdasarkan skala usaha dan sektor ekonomi, serta bagaimana hubungannya dengan penyerapan tenaga kerja?"

Analisis

Mahasiswa dapat melakukan:

EDA → clustering → korelasi → regresi

Contoh pertanyaan:

1. Sektor apa yang memiliki jumlah UMKM paling banyak?
2. Bagaimana distribusi UMKM mikro, kecil dan menengah?
3. Sektor mana yang menyerap tenaga kerja paling banyak?
4. Apakah jumlah UMKM berkorelasi dengan jumlah tenaga kerja?
5. Apakah karakteristik UMKM dapat dikelompokkan menggunakan K-Means?
6. Dapatkah jumlah tenaga kerja diprediksi berdasarkan karakteristik UMKM?

Kelompok 1 — Kemiskinan

Judul:

Analisis dan Prediksi Tingkat Kemiskinan Daerah Menggunakan Data Terbuka Pemerintah

Metode:

EDA + Correlation + Regression

Kelompok 2 — UMKM

Judul:

Segmentasi UMKM Berdasarkan Skala Usaha, Sektor Ekonomi, Tenaga Kerja dan Omzet

Metode:

EDA + K-Means Clustering

Kelompok 3 — Kesehatan

Judul:

Analisis Ketersediaan Fasilitas Kesehatan Antarwilayah

Metode:

EDA + Normalization + Clustering

Data.go.id bahkan menyediakan dataset jumlah sarana kesehatan berdasarkan jenisnya, seperti rumah sakit, puskesmas, klinik, posyandu dan apotek pada level desa/kecamatan dalam beberapa dataset daerah. (Data.go.id)

Kelompok 4 — Harga Bahan Pokok

Judul:

Analisis Perubahan Harga Bahan Pokok Antarwilayah

Metode:

EDA + Time Series + Forecasting

Data.go.id menyediakan dataset **Tingkat Harga Daerah**, termasuk harga rata-rata barang pokok pada tingkat provinsi dengan periode harian. (Data.go.id)

Kelompok 5 — Pendidikan

Judul:

Analisis Hubungan Tingkat Pendidikan dengan Kondisi Sosial Ekonomi Masyarakat

Metode:

EDA + Correlation + Regression

Kelompok 6 — Bantuan Sosial

Judul:

Analisis Sebaran Penerima Bantuan Sosial Berdasarkan Karakteristik Wilayah

Metode:

EDA + Clustering + Visualization

I. Format Laporan Mahasiswa

PROJECT 1

BAB 1 – Problem Definition

1. Latar belakang
2. Rumusan masalah
3. Tujuan analisis
4. Pertanyaan Data Science

BAB 2 – Data Understanding

1. Sumber data
2. Deskripsi dataset
3. Variabel
4. Statistik deskriptif

BAB 3 – Data Preparation

1. Data cleaning
2. Missing value
3. Outlier
4. Data integration
5. Feature engineering

BAB 4 – Exploratory Data Analysis

1. Distribusi data
2. Visualisasi
3. Korelasi

4. Insight awal

Project 2

BAB 5 – Modeling

1. Pemilihan algoritma
2. Training
3. Testing
4. Parameter
5. Hasil model

BAB 6 – Evaluation

Disesuaikan dengan model:

Regression:

- MAE
- RMSE
- R^2

Classification:

- Accuracy
- Precision
- Recall
- F1-score

Clustering:

- Silhouette Score
- Elbow Method

BAB 7 – Insight dan Kesimpulan

Mahasiswa **tidak cukup hanya menampilkan grafik**, tetapi harus menjawab:

"Apa yang dapat kita pelajari dari data?"

dan

"Apa implikasi hasil analisis berdasarkan data tersebut?"

Rubrik Penilaian

Project 1

Komponen	Bobot
Problem formulation	20%
Data understanding & preprocessing	20%
EDA & visualisasi	25%
Laporan	20%
Presentasi	15%
Total	**100%**

Project 2

Komponen	Bobot
Pemilihan metode/model	15%
Implementasi	20%
Evaluasi model	20%
Interpretasi hasil	20%
Rekomendasi	10%
Presentasi	15%
Total	**100%**